

Détection d'événements climatiques extrêmes (B)

Étienne Mitchell-Bouchard, Martin Medina Mejia, Alexis Lavigne,
Rémi Lalonde, Laurent Faucher

1 Revue de littérature

1.1 ClimateNet : an expert-labeled open dataset and deep learning architecture for enabling high-precision analyses of extreme weather [1]

Les premières approches de détection d'événements climatiques extrêmes utilisaient principalement des heuristiques spécifiques au type d'événements. Cependant, les chercheurs avaient souvent des définitions différentes et parfois ambiguës [2].

Prabhat et al. (2020) proposent une approche différente basée sur l'apprentissage profond supervisé [2]. Pour ce faire, ils ont créé l'ensemble de données *ClimateNet*, étiqueté par des experts climatiques [3]. Ils ont développé une interface d'étiquetage, *ClimateContours*, afin d'annoter les rivières atmosphériques (AR) et les cyclones tropicaux (TC) à partir des résultats du modèle atmosphérique CAM5.1 à 25 km [4]. Pour la segmentation, ils ont utilisé l'architecture *DeepLabV3+* avec le backbone de ResNet [5], un réseau de segmentation sémantique qui contient plus de 40 millions de paramètres. Le modèle atteint un IoU (*intersection over union*) de **73,54 %** lorsqu'il est entraîné avec des heuristiques, mais **52,47 %** sur *ClimateNet*. Cette performance est comparable à l'accord moyen entre les experts humains (**51,20 %**). Donc, une performance parfaite est impossible dans ce contexte, car même les experts sont en désaccord sur les frontières des événements. Le modèle atteint alors une performance similaire aux experts humains.

Cette recherche démontre un changement dans la méthodologie qui démontre la puissance de réseaux profonds dans des contextes climatiques, mais limité par le nombre de données étiquetées.

1.2 Spatio-temporal segmentation and tracking of weather patterns with light-weight Neural Networks [2]

Dans la même lignée, Kapp-Schwoerer et al. (2020) ont proposé une approche basée sur l'apprentissage profond privilégiant l'efficacité computationnelle. Les auteurs ont adopté l'architecture *CGNet* développée par Wu et al. (2019) [6] [7], comprenant seulement 494 232 paramètres, soit une réduction d'un facteur 80 par rapport à *DeepLabV3+*. Cette architecture allégée a été entraînée sur un sous-ensemble de quatre variables parmi les seize disponibles dans *ClimateNet* [3] : TMQ, U850, V850 et PSL, sélectionnées en collaboration avec des experts du domaine climatique. Après 15 époques d'entraînement, le modèle a atteint une précision IoU de 59,3 % sur l'ensemble d'entraînement et de **56,1 %** sur l'ensemble de test. Ils proposent aussi un algorithme de détection spatio-temporelle.

1.3 Improving extreme weather events detection with light-weight neural networks [8]

Dans une étude ultérieure, Lacombe et al. (2023) ont exploré la détection des cyclones tropicaux en s'appuyant aussi sur l'architecture *CGNet* et l'ensemble de données *ClimateNet*. Leur approche se différencie par l'évaluation de multiples variantes architecturales, de méthodes d'optimisation, de pertes pondérées et de configurations d'hyperparamètres. Les auteurs ont créé deux nouvelles variables : la vitesse du vent et la vorticité du vent. Contrairement aux travaux précédents qui privilégiaient l'IoU, leur objectif principal consistait à maximiser le rappel, pour minimiser les faux négatifs.

Les auteurs ont mené six expériences afin d'identifier la configuration optimale pour chaque type d'événement extrême (TC et AR). Les résultats montrent que le modèle baseline de Kapp-Schwoerer et al. (2020) atteint un rappel de **57,08 %** pour les TC, tandis que la variante utilisant la perte de Jaccard pondérée surpassé nettement cette performance, avec un rappel de **79,44 %**. Pour les AR,

le baseline obtient **59,93 %** de rappel et l'utilisation d'une perte d'entropie croisée pondérée permet d'atteindre **86,80 %**.

Bien que l'IoU n'était pas la métrique principale, certaines expériences ont tout de même légèrement surpassé le modèle de base selon cette mesure.

1.4 Autres travaux publiés qui peuvent influencer ou inspirer notre projet

- Ronneberger, O., Fischer, P., Brox, T. (2015). *U-Net : Convolutional Networks for Biomedical Image Segmentation*. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI 2015)*

U-Net est l'architecture de référence pour la segmentation d'images scientifiques. Puisque notre référence de base se concentre sur CGNet (un réseau léger), on peut utiliser U-Net comme "baseline" robuste. Il est plus lourd que CGNet, mais il capture souvent mieux les contextes complexes grâce à ses skip connections. Si on veut avoir comme priorité la précision, une architecture comme U-Net pourrait de battre CGNet en sacrifiant un peu les avantages de la légèreté.

- Shi, X., Chen, Z., Wang, H., Yeung, D. Y., Wong, W. K., Woo, W. C. (2015). *Convolutional LSTM Network : A Machine Learning Approach for Precipitation Nowcasting*. In *Advances in Neural Information Processing Systems (NeurIPS 2015)*.

Sur notre référence, les auteurs mentionnent que leur modèle traite les images une par une et ne fait pas de segmentation spatio-temporelle ("our network does not perform spatio-temporal segmentation"). ConvLSTM intègre la mémoire directement dans les convolutions. Cela pourrait permettre à notre modèle d'apprendre le mouvement des cyclones et des rivières atmosphériques directement à partir des données. De cette façon, on peut éviter le post-traitement réalisée dans le papier de référence.

- Cohen, T. S., Geiger, M., Köhler, J., Welling, M. (2018). *Spherical CNNs*. In *International Conference on Learning Representations (ICLR 2018)*.

Les données climatiques sont sur une sphère (la Terre), mais le paper de référence utilise du circular padding pour connecter les bords gauche/droite, mais cela ignore la distorsion aux pôles (haut/bas). Utiliser des Spherical CNNs est une approche mathématiquement plus rigoureuse pour les données planétaires. Cela réduirait les erreurs de détection aux pôles mentionnées dans l'analyse des résultats.

Références

- [1] PRABHAT et al. "ClimateNet : an expert-labeled open dataset and deep learning architecture for enabling high-precision analyses of extreme weather". In : *Geoscientific Model Development Discussions* (2020).
- [2] KAPP-SCHWOERER et al. "Spatio-temporal segmentation and tracking of weather patterns with light-weight Neural Networks". In : *AI for Earth Sciences Workshop at NeurIPS* (2020).
- [3] Andre GRAUBNER. *ClimateNet*. <https://github.com/andregraubner/ClimateNet>. GitHub repository. 2020.
- [4] WEHNER et al. "The effect of horizontal resolution on simulation quality in the Community Atmospheric Model, CAM5.1". In : *Journal of Advances in Modeling Earth Systems* (2014).
- [5] CHEN et al. "Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation". In : *Proceedings of the European Conference on Computer Vision (ECCV)* (2018).
- [6] WU et al. "CGNet : A Light-weight Context Guided Network for Semantic Segmentation". In : *IEEE Transactions on Image Processing* (2019).
- [7] Tianyi Wu. *CGNet*. <https://github.com/wutianyiRosun/CGNet>. GitHub repository. 2019.
- [8] LACOMBE et al. "IMPROVING EXTREME WEATHER EVENTS DETECTION WITH LIGHT-WEIGHT NEURAL NETWORKS". In : *arXiv :2304.00176v1* (2023).