Détection d'événements climatiques extrêmes (B)

Étienne Mitchell-Bouchard, Martin Medina Mejia, Alexis Lavigne,
Rémi Lalonde, Laurent Faucher

1 Méthodes et résultats préliminaires

1.1 Reproduction des baselines

Afin d'établir une base de comparaison pour nos futures expériences et vérifier la reproductibilité des résultats, trois expériences, qui proviennent de la littérature, ont été reproduites. Ces trois expériences utilisent une architecture CGNet sur le jeu de données *ClimateNet*.

1.1.1 Kapp-Schwoerer et al. (2020) [1]

Cette expérience utilise quatre variables (TMQ, U850, V850 et PSL) et est entraînée pendant 15 époques avec un taux d'apprentissage de 0.001. Elle utilise la perte de Jaccard, et sa métrique principale est l'IoU moyen. Les résutlats et comapraison peuvent être vue dans le tableau 1

1.1.2 Lacombe et al. (2023) [2]

Les expériences #5 (entropie croisée pondérée) et #7 (Jaccard pondéré) ont été reproduites. Les deux utilisent les variables TMQ, PSL et PRECT, en plus de deux variables issues de l'ingénierie des caractéristiques (WS850 et VRT850). Les autres hyperparamètres sont identiques à l'expérience précédente. La métrique principale est le rappel, mais d'autres sont aussi évaluées (IoU moyen, score Dice, précision, spécificité).

1.1.3 Écarts de performance

On remarque que les résultats (voir Annexe A) ne sont pas parfaitement identiques. Cela peut s'expliquer puisque quatre fichiers d'entraînement et un fichier de validation étaient corrompus et n'ont pas pu être utilisés. De plus, la taille des lots a dû être diminuée, car les ressources computationnelles ne permettaient pas de garder la configuration initiale. Puis, pour les deux expériences de Lacombe et al. (2023), leur entraînement utilisait du *early stopping* et n'atteignait pas nécessairement 15 époques comme mentionné, en plus d'un *scheduler* pour la décroissance du taux d'apprentissage. Nous avons entraînés les modèles pendant exactement 15 époques.

1.2 UNet

En regardant les résultats pour un UNet standard dans la Table 2, on remarque que ce modèle réussit à mieux performer que les *baselines* dans la catégorie `Rappel`. Ceci s'explique partiellement par une `Précision` basse, ce qui fait que le modèle détecte souvent de faux cas pour s'assurer de ne rater aucun vrai cas. Notre modèle est donc très sensible, mais cela lui permet de ne rater que très peu d'événements extrêmes climatiques. De plus, les résultats d'entraînement et de test sont similaires, prouvant que notre modèle est dans une bonne région de l'apprentissage, autrement dit il ne fait de *overfitting* et il est capable de généraliser correctement.

Pour le UNet avec Attention, dont les résultats sont présentés dans la Table 3, la `Précision` et le `Rappel` sont plus équilibrés, indiquant que le modèle est moins sensible et qu'il arrive mieux à détecter les vrais événements. Le `IoU` est aussi nettement meilleur, indiquant que le modèle est meilleur pour détecter la forme et l'emplacement des événements. Finalement, la `Spécificité` est aussi très bonne. En général, ce modèle performe très bien, et les résultats d'entraînement et de test similaires montrent une bonne généralisation et pas d'*overfitting*. De même, dans certains cas ces résultats des métriques sont meilleurs que les *baselines*.

1.3 ConvLSTM

Avec les UNet on ne traite pas vraiment l'aspect "temporel" du problème car elles traitent chaque image indépendamment et ne prennent pas en compte l'évolution temporelle. Donc, elles ne sont pas vraiment idéales pour les time-series, mais on peut quand même essayer de faire post-processing scheme du paper car son modèle ne faisait pas du spatio-temporal segmentation non plus.

Par contre, il serait intéressant d'utiliser un modèle qui traite les séries, pour cette raison on a implémenté un ConvLSTM. Cependant, en essayant d'entraîner notre modèle avec le cluster, nous rencontrions toujours des `OutOfMemoryError` à cause de la quantité de mémoire des GPUs du cluster. Nous n'avons donc pas pu beaucoup expérimenté, mais nous allons essayer de réduire la taille de notre modèle et expérimenter avec les paramètres des tâches dans le cluster.

Références

[1] KAPP-SCHWOERER et al. "Spatio-temporal segmentation and tracking of weather patterns with light-weight Neural Networks". In : *AI for Earth Sciences Workshop at NeurIPS* (2020).

[2] LACOMBE et al. "IMPROVING EXTREME WEATHER EVENTS DETECTION WITH LIGHT-WEIGHT NEURAL NETWORKS". In : *arXiv :2304.00176v1* (2023).

A Résultats des baselines

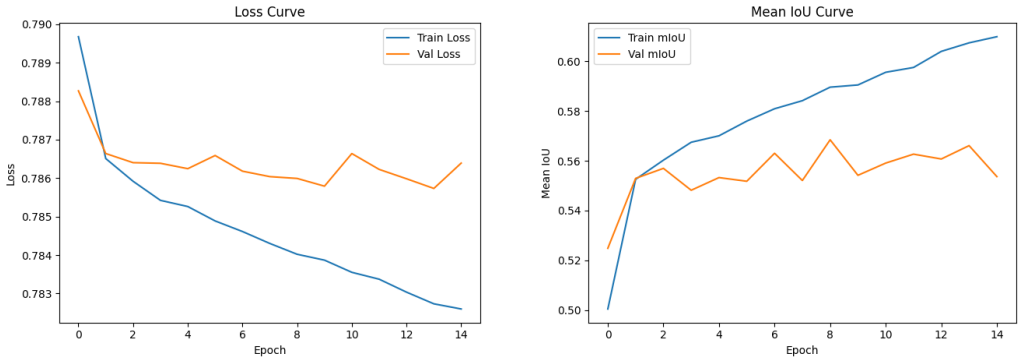

(a) Courbe de la perte

(b) Courbe du IoU moyen pour les 3 classes

FIGURE 1 – Courbe d'apprentissage - Reproduction de l'expérience 2020

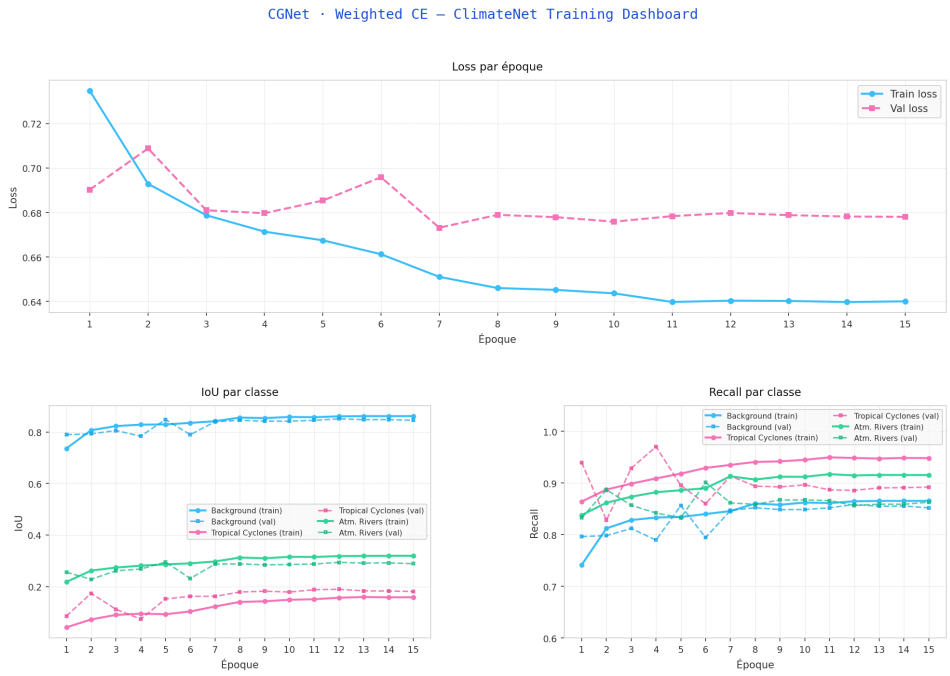

FIGURE 2 – Courbes d'apprentissage - Reproduction de l'expérience #5 (2023)

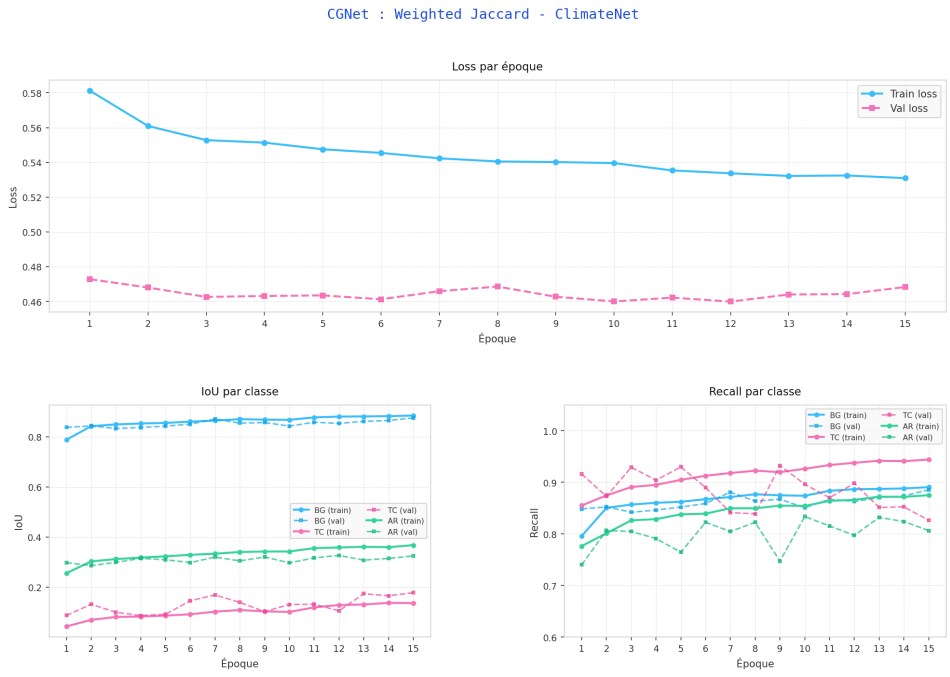

FIGURE 3 – Courbes d'apprentissage - Reproduction de l'expérience #7 (2023)

Tâche	Métrique	2020	Reproduction	2023 #5	Reproduction	2023 #7	Reproduction
TC	**IoU**	0.3396	0.3486	0.2025	0.1769	0.2245	0.1686
	Précision	0.4560	0.4599	0.2145	0.1817	0.2384	0.1748
	Rappel	0.5708	0.5903	0.7836	0.8702	0.7944	0.8254
	Spécificité	0.9962	0.9961	0.9841	0.9783	0.9860	0.9785
AR	**IoU**	0.3983	0.3848	0.2932	0.2936	0.3411	0.3275
	Précision	0.5429	0.4543	0.3069	0.3070	0.3714	0.3544
	Rappel	0.5993	0.7157	0.8680	0.8707	0.8086	0.8120
	Spécificité	0.9701	0.9491	0.8839	0.8836	0.9191	0.9124

TABLE 1 – Comparaison des performances entre les articles originaux et les reproductions

B Résultats UNets

Mode	Tâche	IoU	Rappel	Précision
Entraînement	**TC**	0.1407	0.8865	0.1433
	AR	0.2347	0.9336	0.2387
Test	**TC**	0.1496	0.8702	0.1530
	AR	0.2273	0.9151	0.2321

TABLE 2 – Résultats pour un UNet standard

Mode	Tâche	IoU	Rappel	Précision	Spécificité
Entraînement	**TC**	0.3322	0.6933	0.3894	0.9950
	AR	0.4136	0.6397	0.5392	0.9671
Test	**TC**	0.3495	0.6617	0.4256	0.9951
	AR	0.4014	0.6208	0.5317	0.9676

TABLE 3 – Résultats pour un UNet avec Attention