# Résultats et conclusions - ClimateNet (B)

**Étienne Mitchell-Bouchard, Martin Medina Mejia, Alexis Lavigne, Rémi Lalonde, Laurent Faucher**

## 1 Optimisation des données

Le jeu de données ClimateNet contient presque 30 GB de données et présente un fort déséquilibre de classes (93% *background* (BG)), rendant l'apprentissage des événements extrêmes difficile. Afin de réduire la quantité de données, deux approches de sous-échantillonnage ont été explorées.

La première approche consiste à sélectionner les fichiers contenant les plus grandes proportions de TC et d'AR selon un score pondéré : $s = 12 \times \%_{\text{TC}} + 1 \times \%_{\text{AR}}$, qui reflète le déséquilibre des classes. Un `safe_mask` a également été intégré dans la perte Jaccard afin d'ignorer les zones géographiquement inactives (27% des pixels ne reçoivent jamais l'étiquette TC ou AR). Tel qu'illustré dans la Table 1, cette approche améliore légèrement la détection des AR mais dégrade légèrement celle des TC, tout en réduisant la taille du jeu de données significativement.

Au lieu d'ignorer des fichiers complets, la seconde approche échantillonne des patches de $128 \times 128$ pixels sur tous les fichiers, en ignorant les patches entièrement BG avec un paramètre *BG_ratio*. Un suréchantillonnage des patches TC, la classe la plus sous-représentée, par augmentation ($90°$, $180°$, $270°$) a également été testé. Comme présenté dans la Table 2, un `bg_ratio` de 20% donne le meilleur compromis pour les TC et les AR. Étonnamment, le suréchantillonnage TC améliore davantage la détection des AR que des TC. La Table 3 présente le pourcentage de réduction des données de chaque technique.

## 2 Exploration de nouvelles architechtures

### 2.1 Exploitation du travail futur de l'aticle de 2020 de Kapp-Schwoerer et al.

Deux axes du travail futur du modèle original [1] sont explorés : la quantification d'incertitude et l'apprentissage temporel, ainsi que l'impact du nombre de canaux.

Le CGNet original utilise 4 canaux. Des variantes avec 8 et 20 canaux, incluant des caractéristiques *engineered*, sont évaluées afin d'analyser l'impact de l'information supplémentaire. La quantification d'incertitude est modélisée via MC Dropout en maintenant le modèle en mode entraînement lors de l'inférence, avec 30 passes stochastiques, où la moyenne des sorties *softmax* fournit la prédiction finale et la variance estime l'incertitude pixel par pixel. Enfin, une architecture hybride est explorée, combinant un CGNet préentraîné avec un ConvLSTM appliqué sur les *feature maps* afin d'intégrer la temporalité directement dans le modèle.

Les expériences effectuées portent sur le nombre de canaux, le MC Dropout et les paramètres séquentiels ($T$, $h$). Dans le cas du modèle hybride, l'entraînement est effectué sur un sous-ensemble de données séquentielles ($\sim$92 séquences consécutives), ce qui réduit la quantité de données disponible par rapport au CGNet standard. Les résultats sont présentés en annexe (Tables 4, 5, 6 et Figure 2).

L'ajout de canaux n'améliore pas les performances (Table 4). Le modèle à 4 canaux reste optimal pour TC, les canaux supplémentaires introduisant probablement du bruit ou de la redondance. Le MC Dropout améliore légèrement l'IoU TC sans dégrader AR (Table 6), suggérant un effet d'ensemble réduisant les faux positifs. L'incertitude se concentre aux frontières des événements (Figure 2). Finalement, augmenter la dimension cachée ($h = 64 \rightarrow 128$) améliore l'IoU TC, tandis qu'augmenter la longueur de séquence ($T = 5$) améliore légèrement la mIoU globale mais dégrade fortement TC (Table 5). Cela s'explique par la réduction des séquences valides, pénalisant les classes rares. Un compromis apparaît entre modélisation temporelle et quantité de données.

### 2.2 Exploration d'architectures basées sur les ConvLSTM

La limitation principale des modèles comme CGNet est qu'ils traitent chaque fichier climatique de manière indépendante, sans exploiter la temporalité des événements extrêmes. Pour résoudre ce problème, des architectures ConvLSTM [2] sont explorées pour intégrer le contexte temporel directement dans la segmentation, sans avoir besoin de *post-processing*.

Dû aux contraintes de mémoire des GPU disponibles, les ConvLSTM purs n'ont pas pu être testés en profondeur. Pour cette raison, deux architectures hybrides ont été explorées, soit `ConvLSTM-UNet`, qui combine un encodeur ConvLSTM à quatre niveaux avec un décodeur UNet avec *skip connections*, et une variante, `ConvLSTM-UNet-GC`, qui ajoute un module de contexte global au goulot d'étranglement. Cette variante s'inspire du CGBlock de Kapp-Schwoerer et al. (2020).

Les résultats des expériences les plus pertinentes sont présentés dans la Table 7. Parmi celles-ci, deux approches liées à la structure temporelle des données ont été explorées. En effet, certains fichiers présentent des écarts importants entre eux, tandis que d'autres possèdent plusieurs fichiers pour le même jour. Pour garantir la cohérence temporelle entre les données, deux expériences ont été effectuées. D'abord, l'expérience **8** considère uniquement les fichiers séquentiels du même jour. Cependant, cela réduit le nombre de séquences d'entraînement d'environ 3.3 fois. Ensuite, afin de garder toutes les données, l'expérience **12** ajoute des trames de classe de fond (*background, BG*) entre les écarts temporels des fichiers. Ces deux approches n'améliorent pas les performances.

Parmi les 20 expériences, la meilleure configuration est l'expérience **14** (voir Figure 3), le `ConvLSTM-UNet-GC` avec les 16 caractéristiques, qui dépasse six des huit métriques du baseline, avec un IoU TC de 0.3527 et le meilleur IoU AR de toutes les expériences de 0.3856. Ce modèle ne surpasse toutefois pas les rappels TC et AR du baseline.

## 3 Amélioration du Attention U-Net

### 3.1 Changements dans l'architecture

Pour améliorer le Attention U-Net, plusieurs modifications à l'architecture et à la boucle d'entraînement ont été réalisées, en plus d'ajouter les nouvelles caractéristiques fabriquées :

— **Accumulation de gradient :** Limités par la mémoire GPU, nous avons utilisé un batch size de 2 avec accumulation sur 4 étapes, simulant ainsi un batch de 8. Cela réduit le bruit et stabilise l'apprentissage. Comme les mises à jour ont lieu toutes les 4 itérations, nous avons augmenté le nombre d'époques.

— **Fonction de perte (CrossEntropy + Dice Loss) :** Dans notre implémentation initiale, nous utilisons la CrossEntropy, adaptée à la classification pixel par pixel. Cependant, la Dice Loss optimise directement l'IoU, métrique clé en segmentation, et est mieux adaptée aux données déséquilibrées.

— **Connexions résiduelles :** On a finalement ajouté des connexions résiduelles directement dans les blocs de convolution de l'encodeur pour permettre au gradient de circuler plus facilement dans les couches profondes. Cela aide le modèle à extraire des caractéristiques plus complexes sans souffrir de la disparition du gradient. [3]

En plus de ces approches, pour prévenir le surapprentissage, une couche de *dropout* au niveau du bottleneck a été ajoutée. D'après les résultats du tableau (Table 8), le modèle amélioré sans dropout entraîné sur 25 époques offre le meilleur compromis global. Bien que le modèle de base performe mieux sur les rivières atmosphériques (AR), cette version améliore la précision et l'IoU des cyclones tropicaux (TC). Le dropout n'apporte pas d'amélioration significative.

D'une autre part, on remarque que le prolongement de l'entraînement à 30 époques fait diminuer l'IoU et la précision des cyclones, signifiant que le modèle génère trop de faux positifs et un début de surapprentissage. Pour confirmer cela, on a analysé les courbes d'entraînement du modèle amélioré sans dropout entraîné sur 30 époques.

Bien que la fonction de perte (Figure 4a) démontre une convergence stable, l'IoU sur l'ensemble de test (Figure 4b) atteint sa valeur maximale entre de l'époques 20 et 25 avant de commencer à surapprendre légerement. De plus, les métriques de rappel et de précision (Figures 4c et 4d) sont très volatiles, probablement à cause du petit batch.

En conclusion, la meilleure configuration, offrant un bon compromis entre performance et absence de surapprentissage, est la version améliorée sans dropout entraînée sur 25 époques. Toutefois, le modèle reste sensible aux variations locales des batchs, entraînant une instabilité des métriques.

Pour suivre les événements à travers le temps, il est pertinent d'appliquer u**n système de post-traitement**, comme mentionné dans [4]. Plus de détails seront présentés dans le rapport final par souci de brévité, mais un aperçu est disponible en regardant la table 9 et les figures 5 et 6, qui mènent vers des animations.

## Références


[1] KAPP-SCHWOERER et al. "Spatio-temporal segmentation and tracking of weather patterns with light-weight Neural Networks". In : *AI for Earth Sciences Workshop at NeurIPS* (2020).

[2] Xingjian SHI et al. "Convolutional LSTM Network : A Machine Learning Approach for Precipitation Nowcasting". In : *CoRR* abs/1506.04214 (2015). arXiv : 1506.04214. URL : http://arxiv.org/abs/1506.04214.

[3] Kaiming HE et al. "Deep residual learning for image recognition". In : *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, p. 770-778. URL : https://arxiv.org/abs/1512.03385.

[4] PRABHAT et al. "ClimateNet : an expert-labeled open dataset and deep learning architecture for enabling high-precision analyses of extreme weather". In : *Geoscientific Model Development Discussions* (2020).

[5] Romain LACOMBE et al. *Improving extreme weather events detection with light-weight neural networks*. 2023. arXiv : 2304.00176 [cs.CV]. URL : https://arxiv.org/abs/2304.00176.


## A Optimisation des données

TABLE 1 – Comparaison des expériences de sélection de fichiers avec et sans *safe_mask*. Les valeurs en **gras** indiquent le meilleur résultat par colonne.

| # | Expérience | Cyclone tropical (TC) | | | | Rivière atmosphérique (AR) | | | |
|---|---|---|---|---|---|---|---|---|---|
| | | IoU | Préc. | Rap. | Spéc. | IoU | Préc. | Rap. | Spéc. |
| 0 | Reproduction baseline [1] | **0.3486** | **0.4599** | 0.5903 | **0.9961** | 0.3848 | 0.4543 | 0.7157 | 0.9491 |
| 1 | Top 64% fichiers | 0.3359 | 0.4345 | 0.5970 | 0.9957 | 0.3807 | 0.4502 | 0.7114 | 0.9485 |
| 2 | Top 75% fichiers | 0.3304 | 0.4391 | 0.5718 | 0.9960 | **0.3914** | **0.4973** | 0.6475 | **0.9612** |
| 3 | Top 64% + safe_mask | 0.3193 | 0.3812 | **0.6628** | 0.9941 | 0.3648 | 0.4250 | **0.7200** | 0.9423 |
| 4 | Top 75% + safe_mask | 0.3220 | 0.4061 | 0.6084 | 0.9951 | 0.3910 | 0.4900 | 0.6595 | 0.9593 |

**N. B. :** 64% a été choisi comme seuil pour conserver au moins 90% des pixels TC dans tous les fichiers. À un seuil de 75%, 95,4% des pixels TC sont conservés.

TABLE 2 – Comparaison des expériences d'échantillonnage par patches. $\star$ configuration retenue. Les valeurs en **gras** indiquent le meilleur résultat par colonne.

| # | Expérience | Cyclone tropical (TC) | | | | Rivière atmosphérique (AR) | | | |
|---|---|---|---|---|---|---|---|---|---|
| | | IoU | Préc. | Rap. | Spéc. | IoU | Préc. | Rap. | Spéc. |
| 0 | Reproduction baseline [1] | **0.3486** | 0.4599 | 0.5903 | 0.9961 | 0.3848 | 0.4543 | 0.7157 | 0.9491 |
| 1 | BG 10% | 0.3142 | 0.4395 | 0.5244 | 0.9963 | 0.3829 | 0.4984 | 0.6231 | 0.9628 |
| 2 | BG 15% | 0.3005 | 0.5150 | 0.4191 | **0.9978** | 0.3821 | 0.5464 | 0.5597 | 0.9725 |
| 3 | BG 20% $\star$ | 0.3126 | 0.4538 | 0.5012 | 0.9967 | 0.3854 | 0.5065 | 0.6172 | 0.9644 |
| 4 | BG 25% | 0.3025 | 0.3890 | 0.5764 | 0.9950 | 0.3850 | 0.4890 | 0.6442 | 0.9601 |
| 5 | BG 30% | 0.3061 | 0.4437 | 0.4968 | 0.9966 | 0.3891 | 0.4996 | 0.6377 | 0.9622 |
| 6 | BG 40% | 0.3105 | 0.4422 | 0.5104 | 0.9964 | 0.3680 | 0.4576 | 0.6529 | 0.9542 |
| 7 | BG 20% + all features | 0.3321 | **0.5211** | 0.4781 | 0.9976 | **0.3893** | 0.5242 | 0.6022 | 0.9676 |
| 8 | BG 20% + TC $\times 6$ | 0.3071 | 0.4750 | 0.4650 | 0.9972 | 0.3764 | **0.5513** | 0.5427 | **0.9738** |
| 9 | BG 20% + TC $\times 12$ | 0.2876 | 0.4023 | 0.5021 | 0.9959 | 0.3817 | 0.4995 | 0.6182 | 0.9633 |
| 10 | BG 20% + CE pondérée | 0.3185 | 0.4014 | 0.6068 | 0.9950 | 0.3834 | 0.5185 | 0.5955 | 0.9672 |
| 11 | BG 20% + Jaccard pondérée | 0.2469 | 0.2731 | **0.7207** | 0.9894 | 0.3588 | 0.4179 | **0.7173** | 0.9408 |

TABLE 3 – Réduction de la taille des données selon la technique d'optimisation.

| Technique | Configuration | Train (GB) | | Test (GB) | | Total (GB) | | Réduction (%) |
|---|---|---|---|---|---|---|---|---|
| | | Avant | Après | Avant | Après | Avant | Après | |
| **1** | Top 75% (4 carac.) | 8.45 | 6.34 | 1.30 | 0.98 | 9.75 | 7.31 | 25.0 |
| **1** | Top 64% (4 carac.) | 8.45 | 5.41 | 1.30 | 0.83 | 9.75 | 6.24 | 36.0 |
| **2** | Patches (4 carac.) | 8.45 | 3.49 | 1.30 | 0.86 | 9.75 | 4.35 | **55.4** |
| **2** | Patches (16 carac.) | 25.37 | 15.30 | 3.89 | 4.50 | 29.26 | 19.80 | 32.3 |

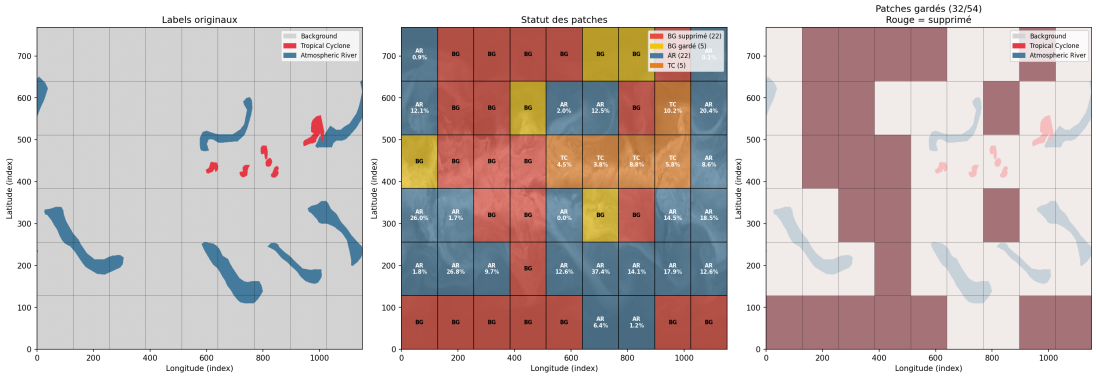


FIGURE 1 – Visualisation des patches : fichier 2010-10-29-01-1_0.nc. Patch 128 x 128, BG_Ratio = 20%, 32/54 patches gardés.

## B Exploitation du travail futur de l'aticle de 2020 [1]

TABLE 4 – Impact du nombre de canaux sur CGNet (époque 15).

| Architecture | mIoU | Cyclone tropical (TC) | | | | Rivière atmosphérique (AR) | | | |
|---|---|---|---|---|---|---|---|---|---|
| | | IoU | Préc. | Rap. | Spéc. | IoU | Préc. | Rap. | Spéc. |
| Reproduction baseline (ch) [1] | 0.5606 | **0.3486** | 0.4599 | **0.5903** | 0.9961 | 0.3848 | 0.4543 | **0.7157** | 0.9491 |
| CGNet 8ch | **0.5634** | 0.3484 | 0.4750 | 0.5665 | 0.9965 | **0.4046** | 0.5065 | 0.6677 | **0.9615** |
| CGNet 8ch + feat. ing. [5] | 0.5601 | 0.3468 | **0.5289** | 0.5018 | **0.9975** | 0.3991 | 0.4858 | 0.6910 | 0.9567 |
| CGNet 20ch | 0.5602 | 0.3382 | 0.4511 | 0.5748 | 0.9961 | 0.3995 | **0.5536** | 0.5894 | 0.9609 |

TABLE 5 – Résultats du modèle hybride CGNet + ConvLSTM (époque 15, dataset engineered†).

| Architecture | mIoU | Cyclone tropical (TC) | | | Rivière atmosphérique (AR) | | |
|---|---|---|---|---|---|---|---|
| | | IoU | Rap. | mIoU | IoU | Rap. | mIoU |
| Hybride $T = 3$, $h = 64$ | 0.486 | 0.193 | 0.618 | 0.486 | 0.360 | 0.841 | 0.486 |
| Hybride $T = 3$, $h = 128$ | 0.488 | **0.209** | 0.614 | 0.488 | 0.353 | 0.841 | 0.488 |
| Hybride $T = 5$, $h = 128$ | **0.491** | 0.111 | 0.282 | **0.491** | **0.445** | 0.809 | **0.491** |

* Les modèles hybrides sont entraînés sur le dataset engineered avec séquences temporelles consécutives (∼92 séquences). La comparaison directe avec le CGNet (dataset complet) n'est pas valide.

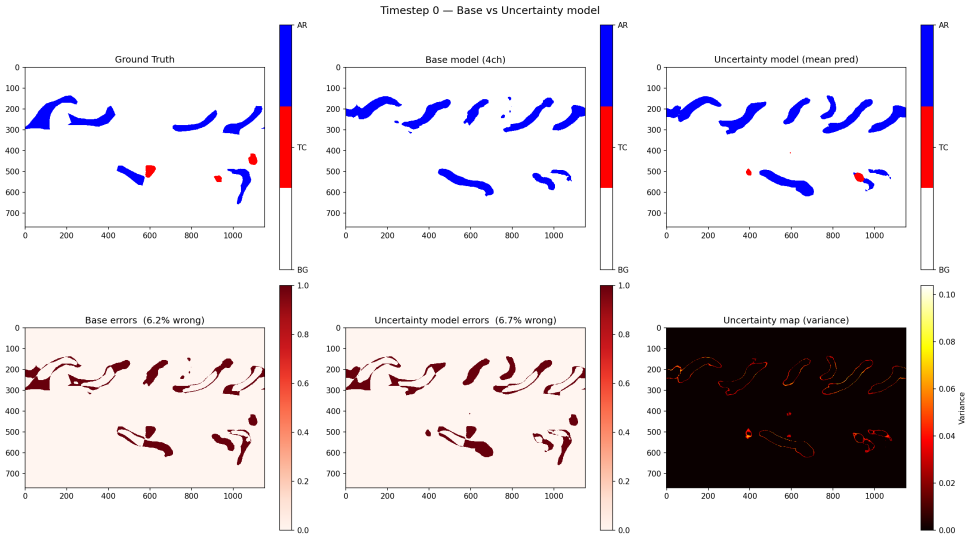


FIGURE 2 – Visualisation de l'incertitude des predictions pour le modèle de base avec quantification d'incertitude.

TABLE 6 – CGNet avec et sans MC Dropout (époque 15).

| **Architecture** | **mIoU** | **Cyclone tropical (TC)** | | | | **Rivière atmosphérique (AR)** | | | |
|---|---|---|---|---|---|---|---|---|---|
| | | IoU | Préc. | Rap. | Spéc. | IoU | Préc. | Rap. | Spéc. |
| Reproduction baseline (ch)[1] | 0.5606 | 0.3486 | **0.4599** | 0.5903 | 0.9961 | 0.3848 | 0.4543 | **0.7157** | 0.9491 |
| CGNet + MC Dropout ($N = 30$) | **0.5645** | **0.3514** | 0.4579 | **0.6017** | 0.9961 | **0.4054** | **0.5048** | 0.6732 | **0.9609** |

# C Expériences basées sur des ConvLSTM

## C.1 Résultats et performances

TABLE 7 – Comparaison des expériences ConvLSTM sur l'ensemble de test (époque 15). Sauf indication contraire : perte d'entropie croisée pondérée $[0.5, 5.0, 2.0]$, caractéristiques TMQ, U850, V850, PSL [1], séquences consécutives, `features=[8, 16, 32, 64]` pour ConvLSTM-UNet, et `hidden_channels=[8, 16, 8]` pour ConvLSTM pur. $T$ = longueur de séquence. †Caractéristiques : TMQ, WS850, VRT850, PSL, PRECT [5]. *OOM : erreur due au manque de mémoire. Les valeurs en **gras** indiquent le meilleur résultat par colonne.

| # | Configuration | Cyclone tropical (TC) | | | | Rivière atmosphérique (AR) | | | |
|---|---|---|---|---|---|---|---|---|---|
| | | IoU | Préc. | Rap. | Spéc. | IoU | Préc. | Rap. | Spéc. |
| *Référence* | | | | | | | | | |
| 0 | Reproduction baseline [1] | 0.3486 | 0.4599 | 0.5903 | 0.9961 | 0.3848 | 0.4543 | 0.7157 | 0.9491 |
| *ConvLSTM-UNet* | | | | | | | | | |
| 1 | ConvLSTM-UNet, $T = 2$ | 0.3569 | 0.4998 | 0.5552 | 0.9969 | 0.3551 | 0.5965 | 0.4673 | 0.9813 |
| 2 | ConvLSTM-UNet, $T = 3$ | 0.3495 | 0.4870 | 0.5531 | 0.9967 | 0.3786 | 0.5235 | 0.5777 | 0.9689 |
| 3 | ConvLSTM-UNet, $T = 4$ | 0.2433 | 0.2587 | **0.8034** | 0.9869 | 0.3771 | 0.5928 | 0.5090 | 0.9794 |
| 4 | #2 avec caractéristiques [5]† | 0.3044 | 0.6330 | 0.3697 | 0.9988 | 0.3788 | 0.4755 | 0.6507 | 0.9575 |
| 5 | #2 avec poids TC=7.0 dans la perte | **0.3699** | 0.5381 | 0.5421 | 0.9974 | 0.3186 | 0.6452 | 0.3863 | 0.9874 |
| 6 | #2 avec poids AR=3.0 dans la perte | 0.2956 | 0.3616 | 0.6184 | 0.9939 | 0.3372 | 0.5847 | 0.4433 | 0.9814 |
| 7 | #2 avec perte de Jaccard | 0.2811 | **0.6351** | 0.3352 | **0.9989** | 0.3454 | 0.5921 | 0.4532 | 0.9815 |
| 8 | #2 avec séquences du même jour seulement | 0.2096 | 0.3313 | 0.3634 | 0.9957 | 0.3807 | 0.5019 | 0.6119 | 0.9609 |
| 9 | #2 avec features=[16, 32, 64, 128] | 0.3457 | 0.4863 | 0.5446 | 0.9968 | 0.3615 | 0.6041 | 0.4738 | 0.9816 |
| 10 | #2 avec 16 caractéristiques | 0.3384 | 0.5196 | 0.4926 | 0.9974 | 0.3808 | 0.5837 | 0.5227 | 0.9779 |
| *ConvLSTM-UNet-GC* | | | | | | | | | |
| 11 | ConvLSTM-UNet-GC, $T = 3$ | 0.3381 | 0.4329 | 0.6069 | 0.9984 | 0.3831 | 0.5389 | 0.5698 | 0.9711 |
| 12 | #11 avec ajout de trames *BG* pour continuité | 0.1716 | 0.5704 | 0.1970 | 0.9992 | 0.2343 | 0.3913 | 0.3687 | 0.9661 |
| 13 | #11 avec dropout = 0.1 | 0.2927 | 0.3330 | 0.7073 | 0.9920 | 0.3746 | 0.4699 | 0.6489 | 0.9567 |
| 14 | #11 avec 16 caractéristiques | 0.3527 | 0.5015 | 0.5431 | 0.9970 | **0.3856** | 0.4961 | 0.6338 | 0.9619 |
| 15 | #14 avec poids [0.36, 30.0, 5.88] | 0.2557 | 0.2768 | 0.7700 | 0.9887 | 0.3474 | 0.3999 | **0.7260** | 0.9355 |
| 16 | #11 avec *CosineAnnealingLR* | 0.3317 | 0.4214 | 0.6092 | 0.9953 | 0.3708 | 0.5414 | 0.5407 | 0.9729 |
| 17 | #11 sur 30 époques | 0.3327 | 0.4531 | 0.5558 | 0.9962 | 0.3450 | 0.5922 | 0.4525 | 0.9816 |
| *Autres architectures limitées par *OOM* | | | | | | | | | |
| 18 | ConvLSTM-UNet (décodeur LSTM), $T = 2$ | 0.3377 | 0.4905 | 0.5201 | 0.9970 | 0.2500 | **0.6916** | 0.2814 | **0.9926** |
| 19 | ConvLSTM pur, $T = 2$ | 0.1325 | 0.1941 | 0.2948 | 0.9932 | 0.2766 | 0.3972 | 0.4768 | 0.9571 |
| 20 | #19 avec hidden_channels=[16, 32, 16] | 0.1372 | 0.2038 | 0.2958 | 0.9936 | 0.2902 | 0.3556 | 0.6120 | 0.9343 |

### C.2 Courbes d'entraînement de l'expérience 14

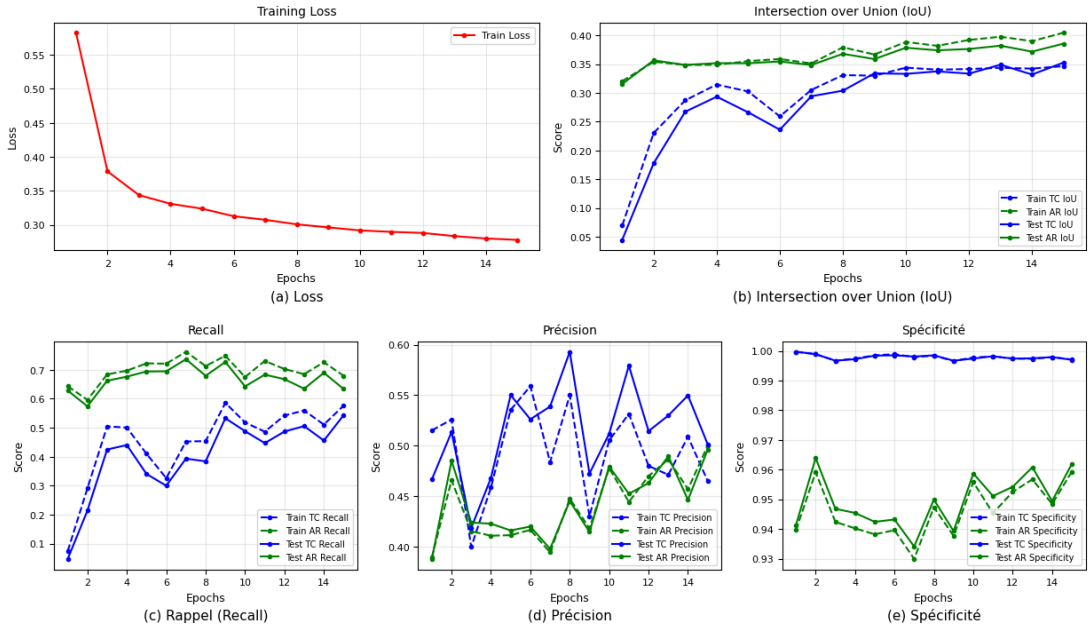


FIGURE 3 – Évolution des métriques d'entraînement et de test pour l'expérience **14** des ConvLSTM.

# D Amélioration du Attention U-Net

## D.1 Résultats et performances

TABLE 8 – Comparaison des performances des architectures Attention U-Net sur l'ensemble de test. Les valeurs en **gras** indiquent le meilleur résultat par colonne.

| # | Configuration | Cyclone tropical (TC) | | | | Rivière atmosphérique (AR) | | | |
|---|---|---|---|---|---|---|---|---|---|
| | | IoU | Préc. | Rap. | Spéc. | IoU | Préc. | Rap. | Spéc. |
| 0 | Base (15 époques) | 0.3495 | 0.4256 | 0.6617 | 0.9951 | **0.4014** | **0.5317** | 0.6208 | **0.9676** |
| 1 | Base + Feature Eng. (15 époques) | 0.3283 | 0.3848 | **0.6909** | 0.9939 | 0.3767 | 0.4701 | 0.6547 | 0.9563 |
| 2 | Amélioré + Feature Eng. (25 époques) | **0.3765** | **0.5216** | 0.5751 | **0.9971** | 0.3879 | 0.4701 | 0.6893 | 0.9540 |
| 3 | Amélioré + Feature Eng. + dropout (25 époques) | 0.3536 | 0.4534 | 0.6164 | 0.9959 | 0.3813 | 0.4551 | **0.7018** | 0.9502 |
| 4 | Amélioré + Feature Eng. (30 époques) | 0.3462 | 0.4104 | 0.6888 | 0.9945 | 0.3846 | 0.4604 | 0.7004 | 0.9514 |

## D.2 Courbes d'entraînement

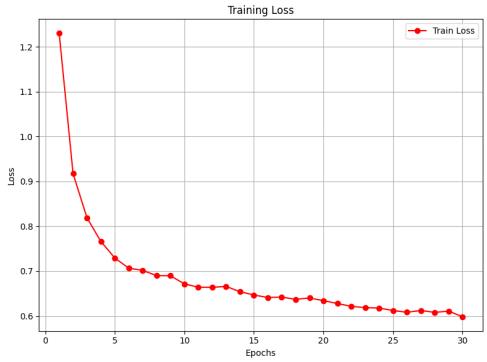


(a) Loss

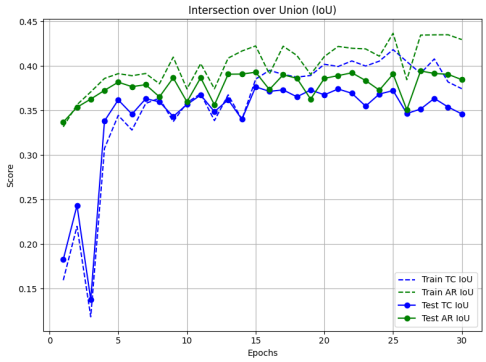


(b) Intersection over Union (IoU)

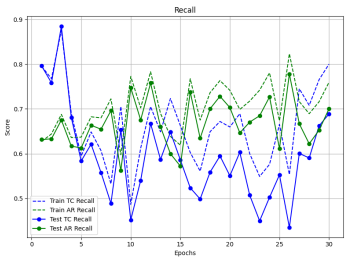


(c) Rappel (Recall)

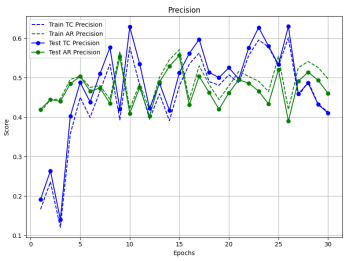


(d) Précision

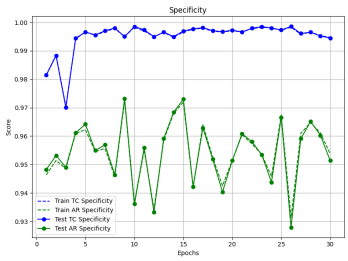


(e) Spécificité

FIGURE 4 – Évolution des métriques d'entraînement et de test sur 30 époques.

## D.3 Post-traitement

| # | Caractéristiques | Cyclone tropical (TC) | | | | Rivière atmosphérique (AR) | | | |
|---|---|---|---|---|---|---|---|---|---|
| | | IoU | Préc. | Rap. | Spéc. | IoU | Préc. | Rap. | Spéc. |
| 1 | 4 Carac. de CGNet | 0.3612 | **0.5772** | 0.4912 | 0.9967 | **0.3873** | 0.6310 | **0.5008** | **0.9627** |
| 2 | 8 Carac. : CGNet + Ingé. | **0.3646** | 0.4753 | **0.6100** | **0.9983** | 0.3800 | 0.6599 | 0.4726 | 0.9564 |
| 3 | 8 Carac. : CGNet + Conservées | 0.3611 | 0.5350 | 0.5263 | 0.9973 | 0.3798 | 0.6807 | 0.4622 | 0.9531 |
| 4 | 12 Carac. : CGNet + Ingé. + Conservées | 0.3590 | 0.4740 | 0.5967 | 0.9982 | 0.3754 | **0.6978** | 0.4483 | 0.9491 |
| 5 | Toutes les 20 carac. | 0.3605 | 0.5749 | 0.4916 | 0.9967 | 0.3694 | 0.6510 | 0.4606 | 0.9548 |

TABLE 9 – Comparaison des performances du Attention U-Net avec différents ensembles de caractéristiques sur l'ensemble de test. Tous les modèles ont été entraînés pour 25 époques. Les valeurs en **gras** indiquent le meilleur résultat par colonne.

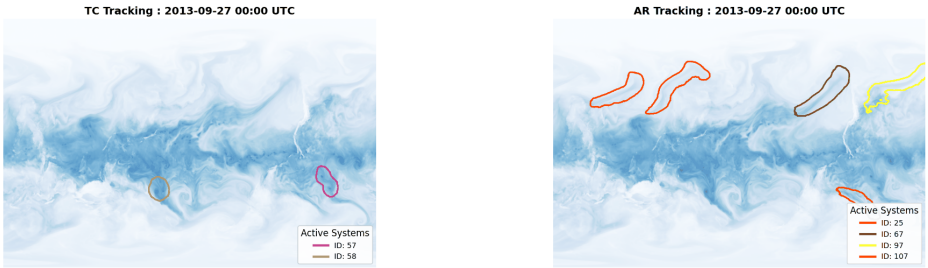


FIGURE 5 – Post-traitement sur l'ensemble de données de test de ClimateNet. Le modèle utilisé est le AttentionUNet entraînés sur les 4 caractéristiques de CGNet pendant 25 epochs. Les images sont des liens vers des GIFs dans le dépôt GitHub.

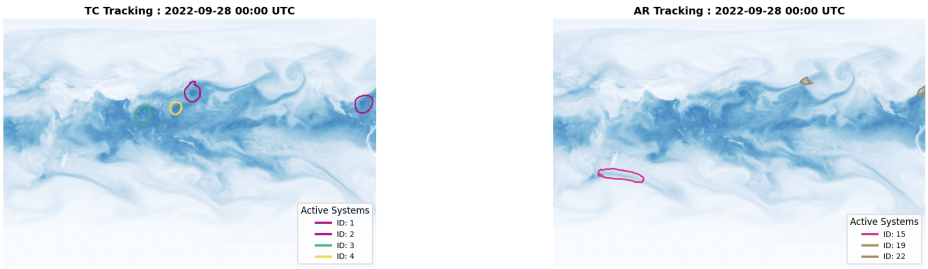


FIGURE 6 – Post-traitement sur l'ensemble de données ERA5 du 26 au 29 septembre 2022. Le modèle utilisé est le AttentionUNet entraînés sur les 4 caractéristiques de CGNet pendant 25 epochs. Les images sont des liens vers des GIFs dans le dépôt GitHub.