Détection d’événements climatiques extrêmes

Étienne Mitchell-Bouchard, Martin Medina Mejia, Alexis Lavigne, Rémi Lalonde, Laurent Faucher

1. Introduction

Contexte

Source: *USA Today*, “Hurricane Douglas skirts north of Hawaii; Texas Hurricane Hanna,” July 27, 2020.

- Impacts majeurs et dévastateurs
- Changement climatique
  - Fréquence et intensité en évolution
  - Imprévisibles
- Gestion des risques

Événements extrêmes ciblés

Cyclones Tropicaux (TC)

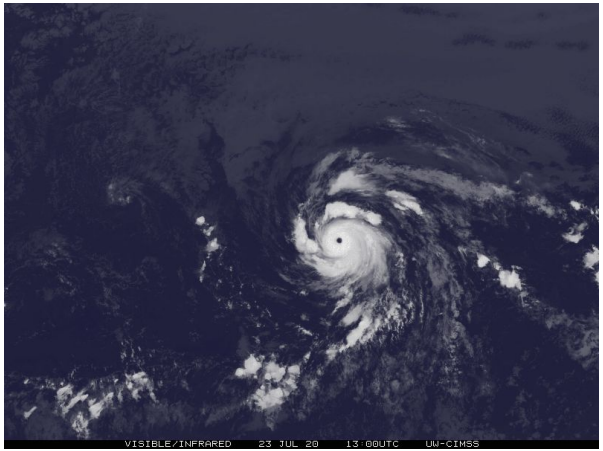

Source: Cooperative Institute for Meteorological Satellite Studies (CIMSS), “Tropical storm Douglas 2020,” July 21, 2020.

- Événements les plus destructeurs
- Vents à très grande vitesse
- Forte rotation locale

Rivières Atmosphériques (AR)

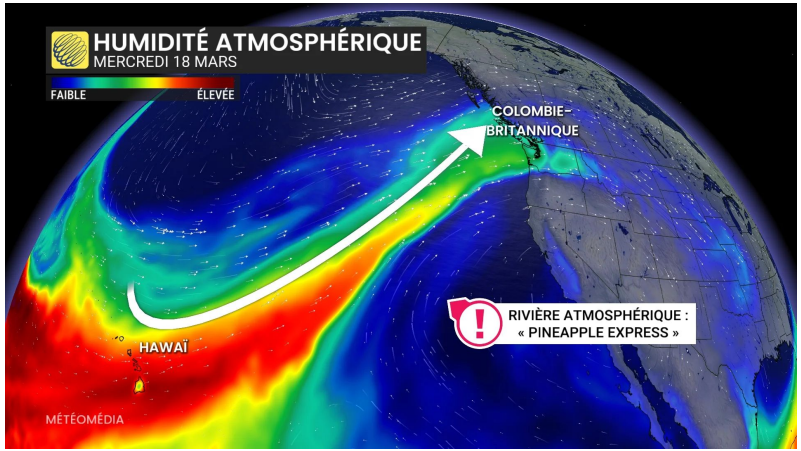

Source: MétéoMédia, “Une forte rivière atmosphérique pourrait causer des avalanches,” 2026.

- Grands corridors d'humidité dans l'atmosphère
- Vapeur d'eau
- Précipitations extrêmes et inondations

Problème

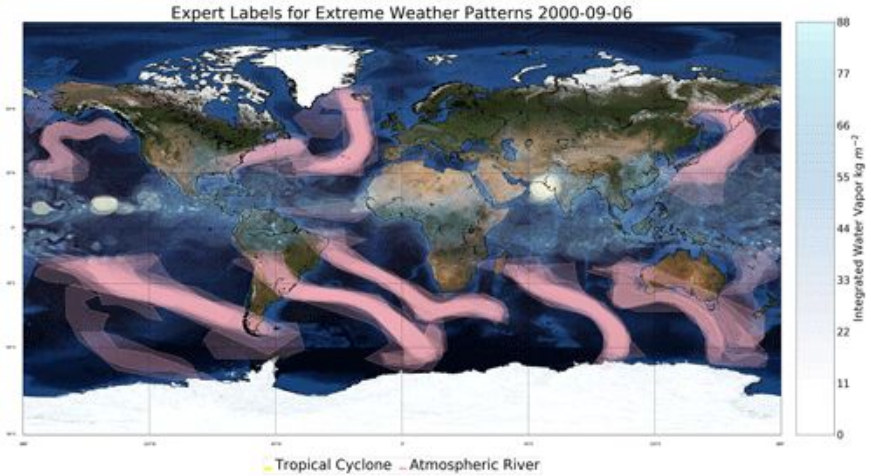

Source: ClimateNet: an expert-labeled open dataset and deep learning architecture for enabling high-precision analyses of extreme weather, Figure 2, 2021.

- Événements rares
  - Débalancement des classes
- Données climatiques lourdes
  - Entraînements lents et exigeants en mémoire
- Analyse du climat comme des images statiques
  - Omission de l'évolution temporelle

Objectifs

- ❖ Réduction du débalancement
- ❖ Réduction des données
- ❖ Innovation sur l'architecture

2. Jeu de données

Le jeu de données ClimateNet

- CAM5.1 annotés par des experts

459 fichiers .nc (~30 GB)

17 × 768 × 1152

canaux latitude longitude

16 variables + étiquette

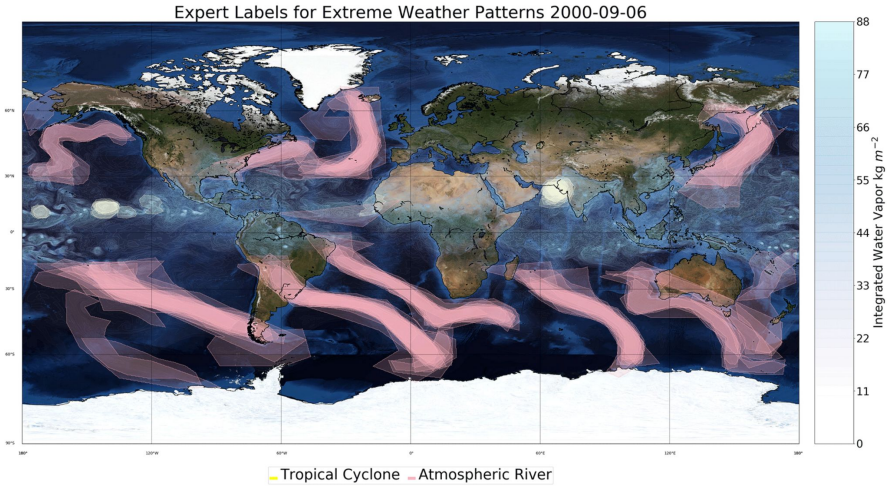

Source: ClimateNet: an expert-labeled open dataset and deep learning architecture for enabling high-precision analyses of extreme weather. Prabhat et al. 2021

Étiquettes (par pixel)

Background (BG) : 93.8%
Rivières atmosphériques (AR) : 5.67%
Cyclones Tropicaux (TC) : 0.462%

- Entraînement* : 1996 - 2010
- Test : 2011 - 2013

❗ Temporalité : pas tous consécutifs

*Séparé en entraînement (1996-2007) et validation (2008-2010)

Les variables atmosphériques

Canal	Description	Unités
TMQ	Eau précipitable totale (intégrée verticalement)	kg/m^2
U850	Vent zonal au niveau de la surface de pression de 850 hPa	m/s
V850	Vent méridional au niveau de la surface de pression de 850 hPa	m/s
PSL	Pression au niveau de la mer	Pa
PRECT	Taux de précipitations total (convectif et à grande échelle)	m/s
WS850	Vitesse du vent au niveau de 850 hPa	m/s
VRT850	Vorticité relative du vent au niveau de 850 mbar	m/s
	…	

+ ingénierie des caractéristiques

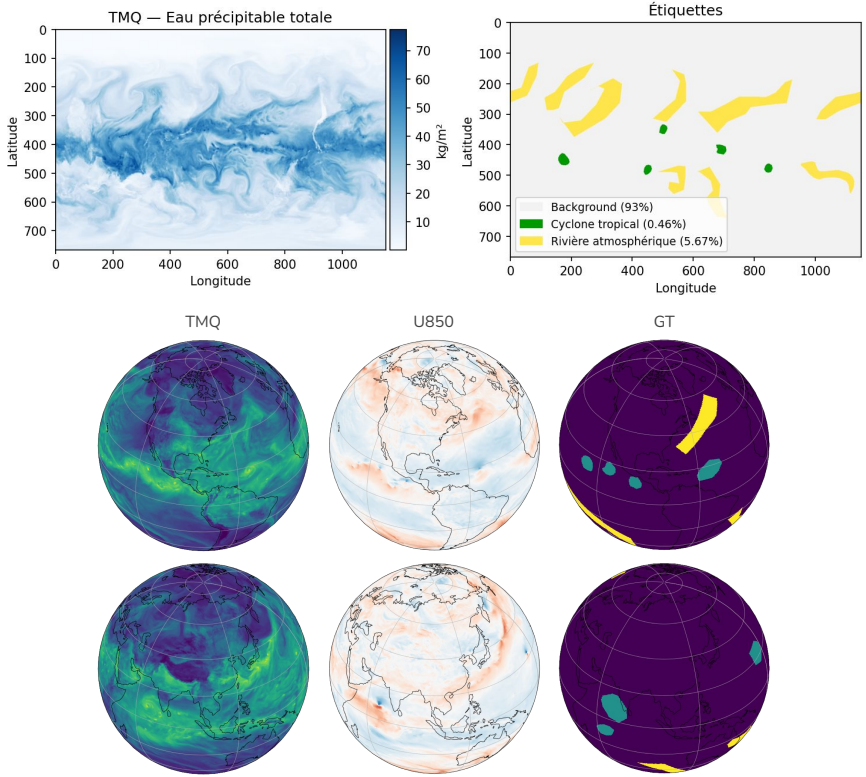

Sample ClimateNet channels and associated ground truth labels. AR: yellow; TC: green; BG: purple. Viewed from 35° N 80°W (above) and 35°N 100°E (below). Source: Improving extreme weather events detection with light-weight neural networks. Lacombe et al. 2023

3. Optimisation des données

2 problèmes principaux

1. Taille du jeu de données (~30 GB)
2. Classes déséquilibrés

→ Solutions:

- Oversampling
- Undersampling
- Augmentation de données
- Ajout de poids dans la fonction de perte

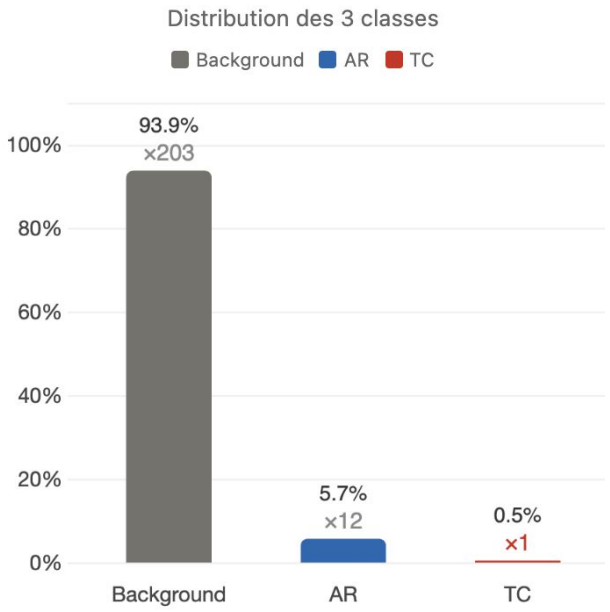

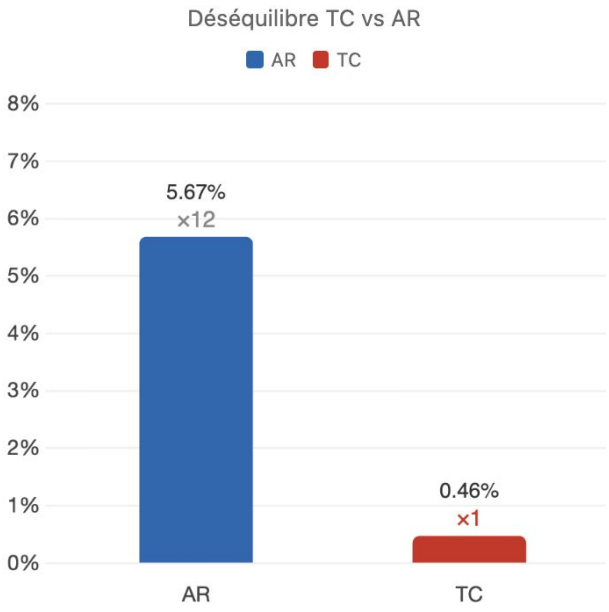

Sampling

$$s = \alpha \times \%_{TC} + \beta \times \%_{AR}$$

où $\alpha = 12$ et $\beta = 1$

1. Sampling par fichier .nc avec score (s)
2. Sampling par patch 128x128 (avec 20% de BG_ratio) → 54 patch / image

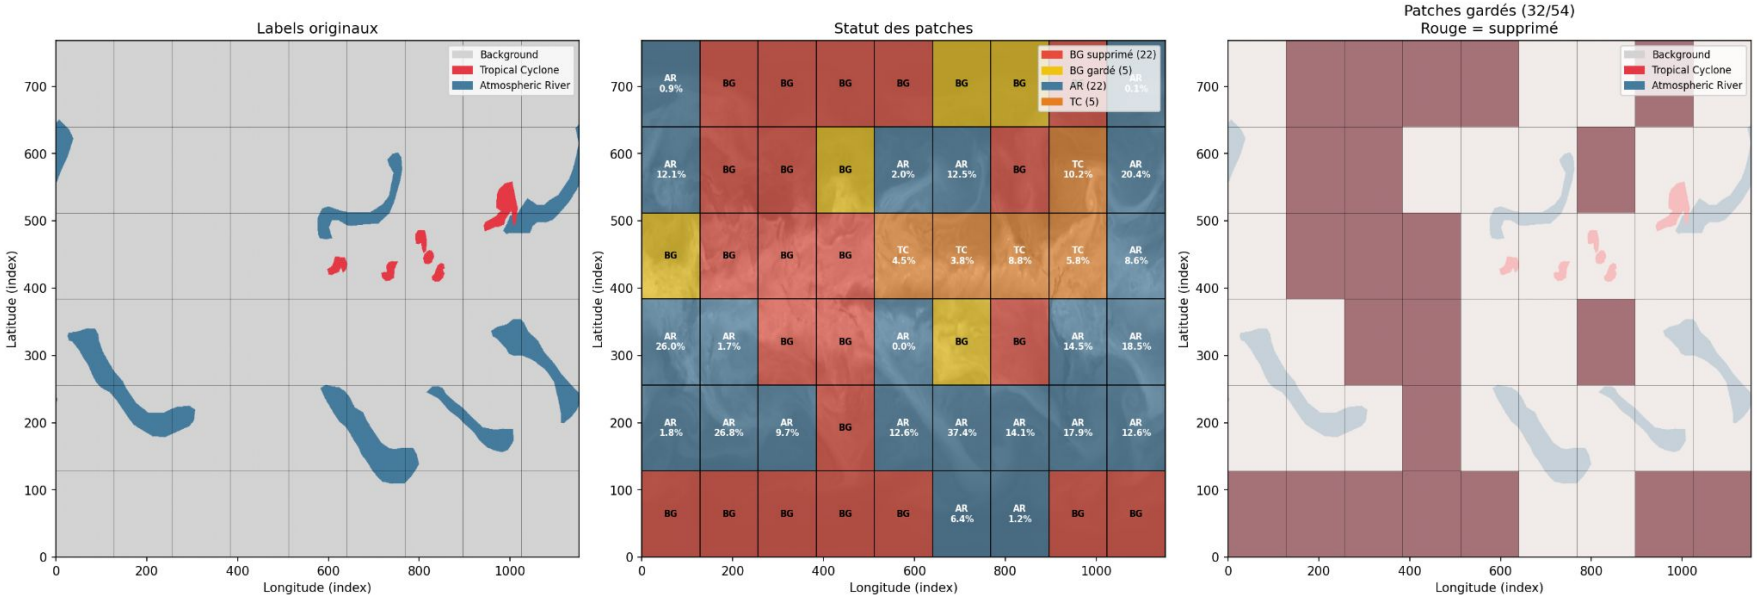

Résultats des méthodes de sampling

Résultats similaires au baseline mais légèrements inférieurs pour la détection de TC

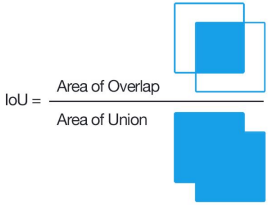

→ Autre pistes:

- Changement d'architecture

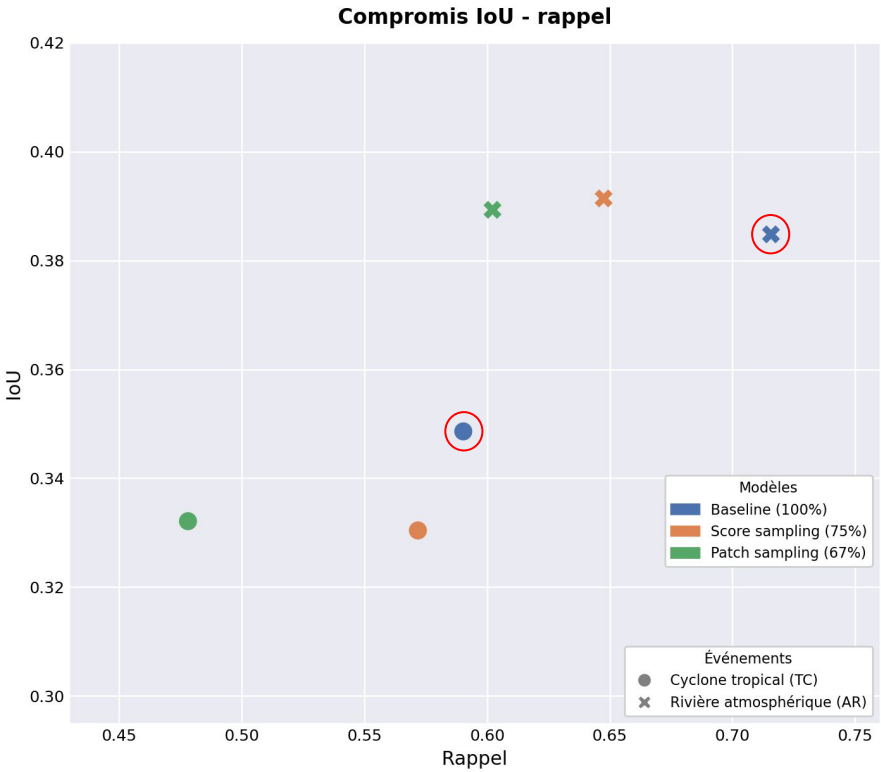

Baseline : Kapp-Schwoerer et al. (NeurIPS 2020)

4. Modèles testés

Familles de modèles testées

Référence

Baseline / CGNet

- Modèle de base
- Segmentation spatiale compacte
- Point de comparaison principal

Temporel

ConvLSTM

- Ajoute une mémoire temporelle
- Utile pour l'évolution des systèmes météo
- Plus complexe à entraîner

Spatial

U-Net

- Architecture classique encodeur-décodeur
- Bonne base pour la segmentation
- Facile à améliorer

Spatial + focus

Attention U-Net

- Ajoute un module d'attention
- Met l'accent sur les régions pertinentes
- Particulièrement intéressant pour le TC

Spatio-temporel

Hybride

- Combine CGNet et ConvLSTM
- Capte mieux la dynamique temporelle

Message : toutes les familles sont utiles, mais l'amélioration du TC reste prioritaire car c'est la classe la plus difficile et souvent la plus importante à mieux détecter.

Résultats : meilleur modèle par famille

Lecture rapide

- Chaque famille a un compromis différent
- La baseline reste une référence utile
- **Attention U-Net obtient le meilleur TC IoU**
- **C'est le choix le plus cohérent pour le projet**

Baseline
bleu
point de référence

Retenu
rouge
cercle rouge

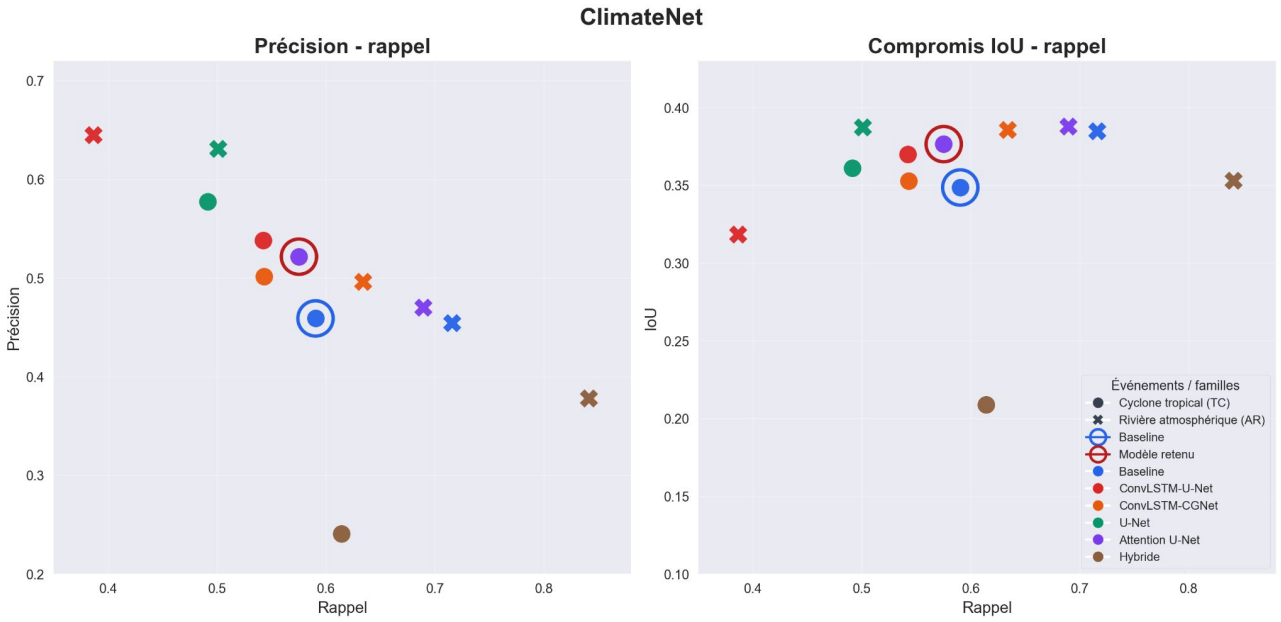

Conclusion : le modèle retenu n'est pas le meilleur sur toutes les métriques, mais c'est celui qui offre le meilleur compromis global avec la meilleure performance TC, donc le choix le plus cohérent pour le projet.

Résultats : baseline vs Attention U-Net

Lecture rapide

- **TC IoU : 0.3495 -> 0.3765**
- AR IoU : 0.4014 -> 0.3879
- **Précision TC : 0.4256 -> 0.5216**
- Rappel TC : 0.6617 -> 0.5751
- AR rappel : 0.6208 -> 0.6893
- Gain clair sur TC, léger recul sur AR

Δ TC IoU
+0.0270
amélioration

Δ AR IoU
-0.0135
léger recul

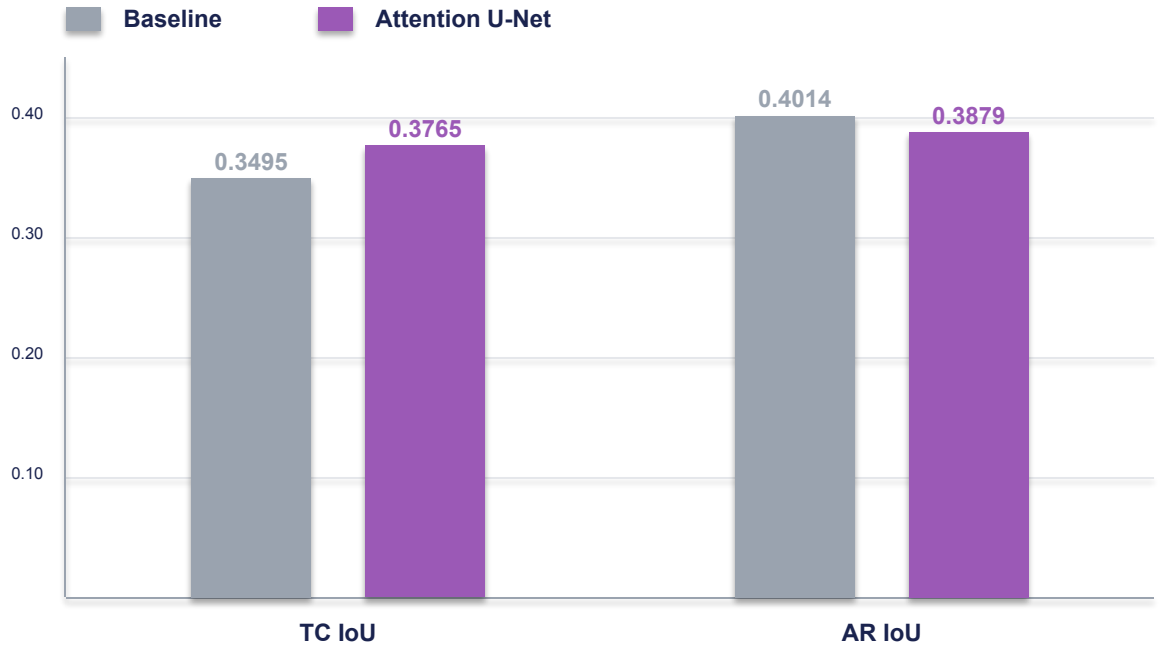

Le graphique montre le point principal : le modèle retenu améliore la détection TC, même si la baseline reste légèrement meilleure sur l'AR IoU.

Choix final et justification

Décision finale

Modèle conservé

Attention U-Net

- Meilleur compromis global parmi les variantes testées
- Bon équilibre entre robustesse et qualité TC

Variante retenue pour la suite

Forces

Pourquoi ce choix

- **Meilleur TC IoU : 0.3765**
- **Meilleure précision TC : 0.5216**
- Le TC est la classe la plus difficile et la plus prioritaire à améliorer

Compromis le plus équilibré

Conclusion : le modèle retenu n'est pas le meilleur sur toutes les métriques AR, mais c'est celui qui offre le meilleur compromis global avec la meilleure performance TC, donc le choix le plus cohérent pour le projet.

5. Post-traitement et application à un événement récent

Post-traitement

- Nos modèles segmentent les événements à un certain moment précis
- Cependant, les événements ne sont pas statiques et évoluent dans le temps
- Pour mieux comprendre leur évolution, il est intéressant de les suivre sur de nombreuses prédictions
- Pour ce faire, on assigne un ID aux événements en regardant la superposition des pixels avec les mêmes classes
- On ne considère pas les événements trop petits (< 200 pixels^2) ou trop court (< 12 heures)

Le post-traitement n'améliore pas la performance de nos modèles.
Il permet de mieux visualiser, analyser et comprendre les prédictions de ceux-ci.

Visualisation des ARs globales

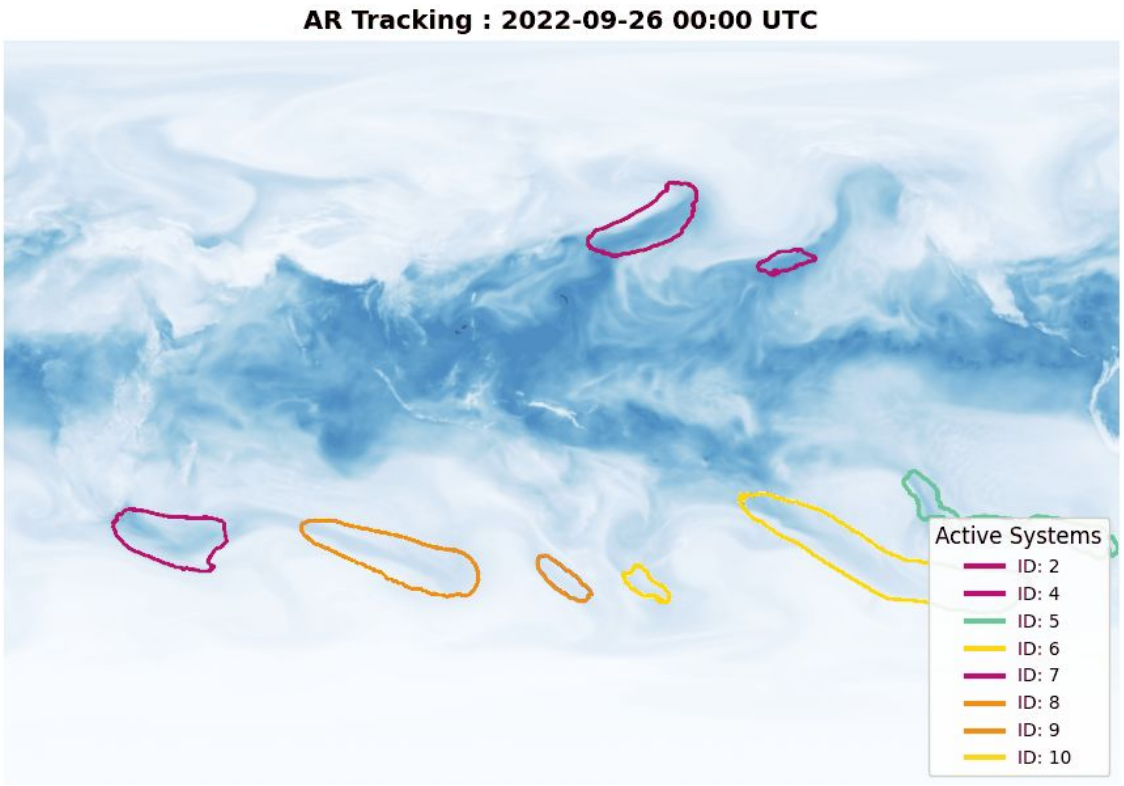

Application à un événement concret: L'ouragan Erin

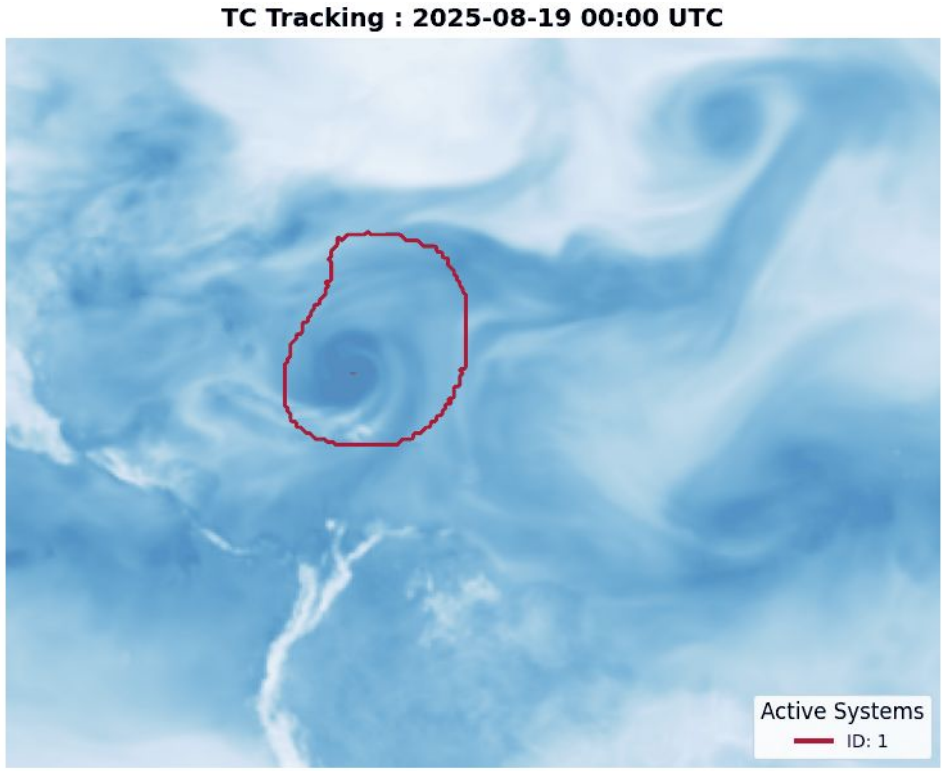

6. Travail futur et conclusion

Travail futur

- Plus de données étiquetées!
- Exploration de méthodes auto-supervisées (self-supervised learning)
- Exploration d’autres architectures et de modèles avec plus de paramètres

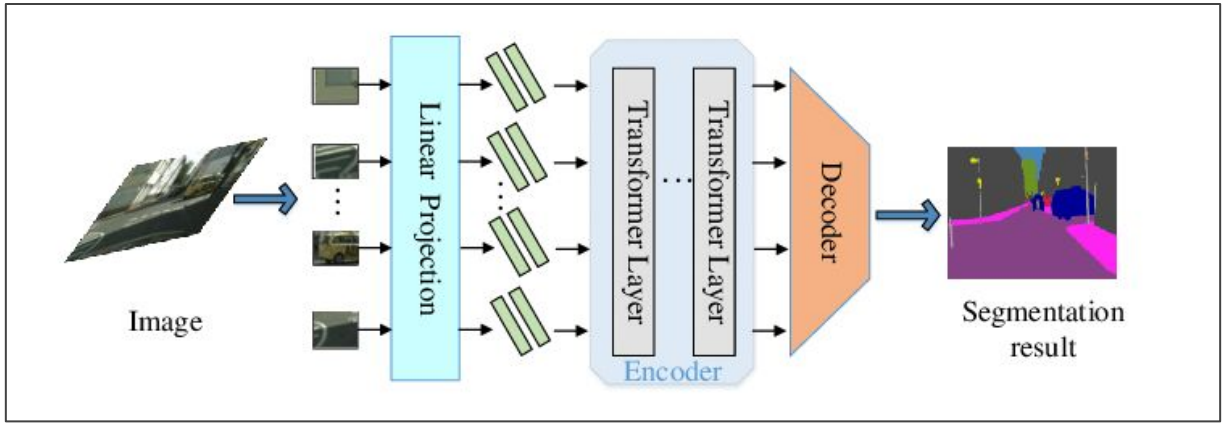

Conclusion

- Sujet important considérant le réchauffement climatique!
- Problème intéressant avec beaucoup de possibilités d’améliorations

Merci!